

“kNN, Linear regression, and multilinear regression”

Chavez Miguel Angel 80811

Ducuara Quesada Daniela 85742

Garcia Castillo Fernando 61865

Mora Andres Acevedo 55305

Morales Javier Sebastian 73322

Palacios Diego Alejandro 46026

2023-04-21

-Enlace de GitHub: <https://github.com/Khallavan/sensorsTraining>

Machine Learning

Machine Learning es una forma de la inteligencia artificial que permite crear modelos estadísticos y algoritmos, en donde la máquina aprende de los datos, mas no mediante la programación predeterminada. Estos modelos pueden procesar grandes cantidades de datos y por medio del entrenamiento identificar patrones de los datos, lo que permite crear modelos mas precisos en la predicción de la información de salida.

¿Que es KNN?

KNN, en ingles K Nearest Neighbor, es un algoritmo que utiliza la “similitud de características” para predecir los valores de los nuevos puntos de datos, lo que significa que al nuevo punto de datos se le asignara un valor en función de que tan cerca concide los puntos en el conjunto de entrenamiento. algunas de las características que tiene el KNN son:

- utiliza conjuntos de datos de entrada etiquetados para asi poder predecir la salida de los datos. -Es un algoritmo de aprendizaje simple y puede ser implementado facilmente para un conjunto variado de problemas.
- Se basa principalmente en la similitud de características, es decir, verifica cuán similares es un punto de datos con relacion a su vecino y clasifica el punto de datos en la cl...

Regresion lineal y multilineal

Un analisis de regresión lineal se utiliza para predecir el valor de una variable según el valor de la otra, por lo que estima los coeficientes de la ecuacion lineal, la regresion lineal se ajusta a una linea recta lo que minimiza discrepancias entre los valores de salida previsto y los reales. El modelo de regresion lineal se considera relativamente

sencillo ya que proporciona una formula matematica facil de interpretar que puede generar predicciones.

El modelo de regresión multilíneal, es un modelo estadístico que permite generar un modelo lineal en el que el valor de la variable dependiente, se determina a partir de un conjunto de variables independientes llamadas “predictores”. ## Resumen:

En el presente informe se realiza una adquisición de datos de dos sensores diferentes que se adaptan a un carrito robot, esto con el fin de tomar los datos que arroja cada sensor a diferentes distancias sobre una superficie (pared) plana, cóncava y convexa. Los dos sensores utilizados fueron los siguientes: Ultrasonido HCR-04 Y Laser VL53L0X. Se realiza los siguientes pasos para poder tomar los datos:

##1. Adquisición de datos Desarrollar un sistema de adquisición (hardware y software) para capturar datos de distancia.

-Se acondicionaron dos sensores, un ultrasonido y uno láser. El ultrasonido entrega el valor que tarda la onda en emitir y recibirla. Para el láser se tomaron mediciones directas en longitud, esto para poder generar los modelos de entrenamiento y predicción sin usar librerías que suministren la curva o ecuación característica del comportamiento de los sensores, ya que se verían afectados los valores con los modelos definidos.

- La primera distancia se toma desde 10 cm desde la pared, y se fue aumentando la distancia cada 10 cm, para llegar a un máximo de 50 cm de distancia. En cada distancia se tomaron 40 observaciones.
- 2. Se tomaron los datos y se registran en un archivo .csv. A continuación se carga el archivo para poder ver los datos para cada sensor y con cada superficie.

```
load_datasets <- function(name_dataset) {  
  if(!require(tidyverse))  
    install.packages("tidyverse")  
  library(tidyverse)  
  
  folder <- dirname(rstudioapi::getSourceEditorContext())$path)  
  parentFolder <- dirname(folder)  
  sensors <- read.csv2(paste0(parentFolder, "/datasets/", name_dataset))  
  return (sensors)  
}
```

Esta función load_datasets se encarga de leer los datasets que están cargados en el repositorio. Lee los archivos .csv que están separados por punto y coma y por ello se emplea la función (read.csv2)

1.1 Carga de datasets

```
if(!require(tidyverse))  
  install.packages("tidyverse")  
  
## Loading required package: tidyverse
```

```
## — Attaching core tidyverse packages —————
tidyverse 2.0.0 —
## ✔ dplyr      1.1.1      ✔ readr      2.1.4
## ✔ forcats   1.0.0      ✔ stringr    1.5.0
## ✔ ggplot2   3.4.1      ✔ tibble     3.2.1
## ✔ lubridate 1.9.2      ✔ tidyr      1.3.0
## ✔ purrr     1.0.1
## — Conflicts —————
tidyverse_conflicts() —
## ✖ dplyr::filter() masks stats::filter()
## ✖ dplyr::lag()     masks stats::lag()
## ⓘ Use the http://conflicted.r-lib.org/conflicted package to
force all conflicts to become errors

library(tidyverse)
sensors.df <- load_datasets("sensors_dataset_A.csv")
ultrasonic.data <- sensors.df %>% select(ultrasonic, distance)
laser.data <- sensors.df %>% select(laser, distance)
multi.data <- sensors.df %>% select(ultrasonic, laser, distance)
```

Aquí se carga el dataset con el nombre de sensors.df. A continuación, se muestra una pequeña parte de los datos:

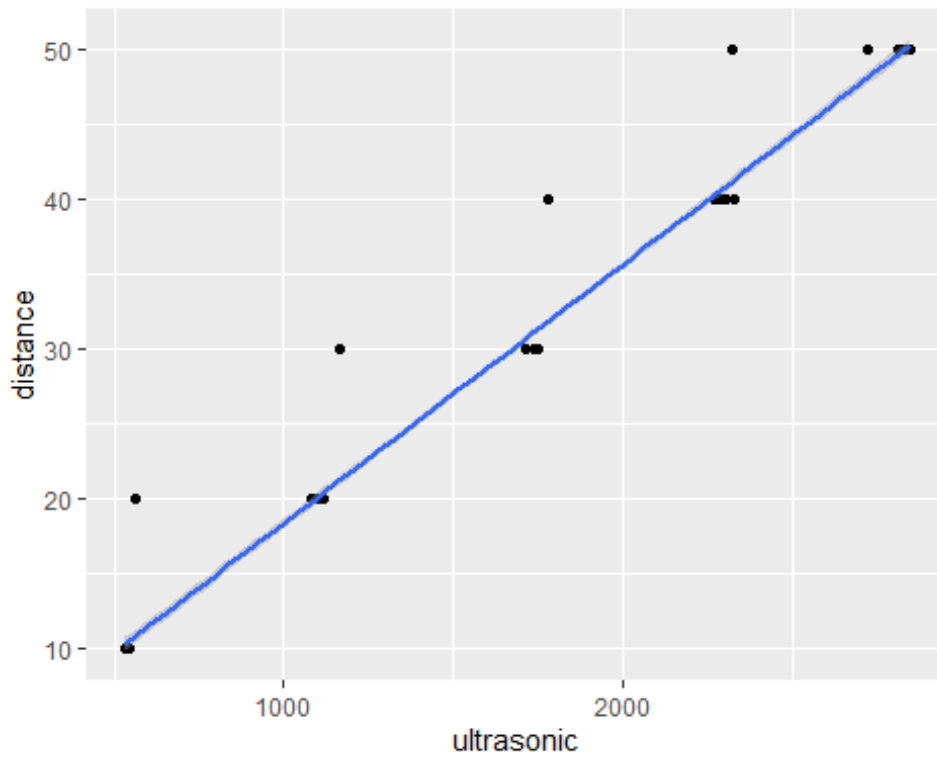
```
head(multi.data)

##   ultrasonic laser distance
## 1         542   108        10
## 2         541   106        10
## 3         541   106        10
## 4         535   108        10
## 5         535   108        10
## 6         536   107        10
```

1.2 visualización de los datos en gráfica de dispersión


```
if(!require(ggplot2))
  install.packages("ggplot2")
library(ggplot2)
ultrasonic.data %>%
  ggplot(aes(x = ultrasonic, y = distance)) +
  geom_point() +
  geom_smooth(method = "lm")

## `geom_smooth()` using formula = 'y ~ x'
```



Gráfica de los datos del sensor ultrasonico.

```
if(!require(ggplot2))
  install.packages("ggplot2")
library(ggplot2)
laser.data %>%
  ggplot(aes(x = laser, y = distance)) +
    geom_point() +
    geom_smooth(method = "lm")
## `geom_smooth()` using formula = 'y ~ x'
```

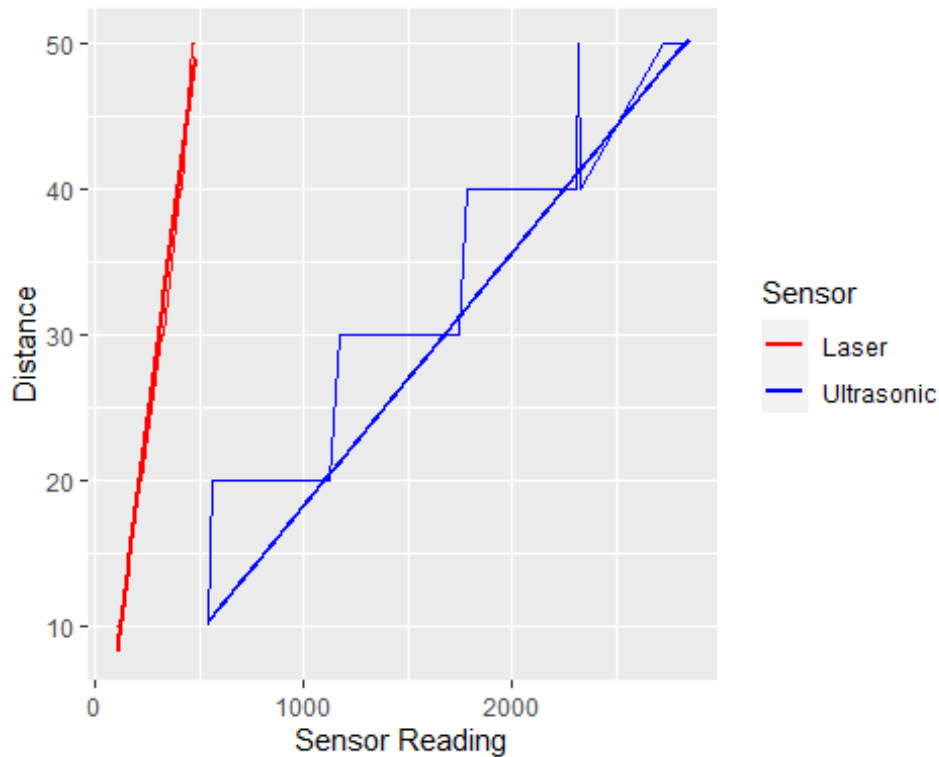


Gráfica de los datos del sensor Laser.

La siguiente gráfica se mostraran la dispersión de los datos de los dos sensores.

```
if(!require(ggplot2))
  install.packages("ggplot2")
library(ggplot2)
multi.data %>%
  ggplot(aes(y = distance)) +
    geom_line(aes(x = ultrasonic, color = "Ultrasonic")) +
    geom_line(aes(x = laser, color = "Laser")) +
    geom_smooth(aes(x = ultrasonic, color = "Ultrasonic"), method = "lm",
se = FALSE) +
    geom_smooth(aes(x = laser, color = "Laser"), method = "lm", se =
FALSE) +
    scale_color_manual(name = "Sensor", values = c("Ultrasonic" = "blue",
"Laser" = "red")) +
    labs(y = "Distance", x = "Sensor Reading")

## `geom_smooth()` using formula = 'y ~ x'
## `geom_smooth()` using formula = 'y ~ x'
```



1.2 Preparación de datos para cada modelo

Se usa la librería caret para realizar el entrenamiento de los modelos predictivos mediante la automatización de tareas comunes, como la normalización de datos, la creación de modelos, la validación cruzada y la evaluación de modelos.

Para una mejor claridad de los datos se emplea y para su posterior replicación en caso de que se requiera, se utiliza una semilla predeterminada.

```
if(!require(caret))
  install.packages("caret")

## Loading required package: caret
## Loading required package: lattice
##
## Attaching package: 'caret'
## The following object is masked from 'package:purrr':
##
##   lift

library(caret)
set.seed(1)
ultrasonic.train.samples <- ultrasonic.data$distance %>%
  createDataPartition(p = 0.8, list = FALSE)
laser.train.samples <- laser.data$distance %>%
```

```

createDataPartition(p = 0.8, list = FALSE)
multi.train.samples <- multi.data$distance %>%
  createDataPartition(p = 0.8, list = FALSE)

ultrasonic.train.data <- ultrasonic.data[ultrasonic.train.samples,
                                          c("ultrasonic", "distance")]
ultrasonic.test.data <- ultrasonic.data[-ultrasonic.train.samples,
                                          c("ultrasonic", "distance")]

laser.train.data <- laser.data[laser.train.samples, c("laser",
"distance")]
laser.test.data <- laser.data[-laser.train.samples, c("laser",
"distance")]
multi.train.data <- multi.data[multi.train.samples, c("ultrasonic",
"laser", "distance")]
multi.test.data <- multi.data[-multi.train.samples, c("ultrasonic",
"laser", "distance")]

```

Implementando la función de caret, entrenamos un modelo de regresión lineal para cada sensor y un modelo multilíneal empleando ambos sensores. La ventaja que nos proporciona la librería Caret es que simplifica los valores de predicción R^2 , MAE y RMSE.

1.3 Entrenamiento de los modelos

```

model.distance.ultrasonic <- train(
  distance ~ ultrasonic,
  data = ultrasonic.train.data,
  method = "lm",
  trControl = trainControl("cv", number = 10)
)
model.distance.laser <- train(
  distance ~ laser,
  data = laser.train.data,
  method = "lm",
  trControl = trainControl("cv", number = 10)
)
model.multi.distance <- train(
  distance ~ ultrasonic + laser,
  data = multi.train.data,
  method = "lm",
  trControl = trainControl("cv", number = 10)
)

```

-En esta parte usamos la otra parte del 20% de los datos separados.

```

predict.ultrasonic <- model.distance.ultrasonic %>%
  predict(ultrasonic.test.data)
predict.laser <- model.distance.laser %>% predict(laser.test.data)
predict.multi <- model.multi.distance %>% predict(multi.test.data)

```

```
postResample(predict.ultrasonic, ultrasonic.test.data$distance)
```

```
##      RMSE  Rsquared      MAE  
## 1.5587459 0.9884411 0.6708602
```

```
postResample(predict.laser, laser.test.data$distance)
```

```
##      RMSE  Rsquared      MAE  
## 1.430263 0.989803 1.351133
```

```
postResample(predict.multi, multi.test.data$distance)
```

```
##      RMSE  Rsquared      MAE  
## 1.2553884 0.9930187 1.0816251
```

-Prueba de los modelos en base a un dataset con los datos de los sensores capturados de forma aleatoria.

```
new_df_test <- load_datasets("random_dataset_sensors_A.csv")  
df_test_cleared <- new_df_test %>% select(ultrasonic, laser)  
df_test_ultrasonic <- df_test_cleared %>% select(ultrasonic)  
df_test_laser <- df_test_cleared %>% select(laser)
```

```
predict(model.multi.distance, df_test_cleared)
```

```
##      1      2      3      4      5      6      7  
8  
## 7.284619 7.284619 7.035488 7.035488 7.213829 7.213829 7.426199  
7.426199  
##      9     10     11     12     13     14     15  
16  
## 7.318648 7.318648 7.355409 7.355409 7.426199 7.426199 7.318648  
7.318648  
##     17     18     19     20     21     22     23  
24  
## 7.496989 7.496989 7.426199 7.426199 7.318648 7.318648 7.213829  
7.213829  
##     25     26     27     28     29     30     31  
32  
## 7.349282 7.349282 7.312521 7.312521 7.496989 7.496989 11.178064  
11.178064  
##     33     34     35     36     37     38     39  
40  
## 16.064234 16.064234 16.875714 16.875714 16.946504 16.946504 17.105803  
17.105803  
##     41     42     43     44     45     46     47  
48  
## 16.964885 16.964885 16.970350 16.970350 16.930856 16.930856 16.964885  
16.964885  
##     49     50     51     52     53     54     55  
56  
## 16.817178 16.817178 16.894095 16.894095 16.894095 16.894095 17.100338
```


17.100338							
##	57	58	59	60	61	62	63
64							
##	16.946504	16.946504	16.894095	16.894095	17.029548	17.029548	16.964885
16.964885							
##	65	66	67	68	69	70	71
72							
##	16.964885	16.964885	16.964885	16.964885	17.177255	17.177255	17.143226
17.143226							
##	73	74	75	76	77	78	79
80							
##	16.964885	16.964885	16.823305	16.823305	16.964885	16.964885	17.111930
17.111930							
##	81	82	83	84	85	86	87
88							
##	16.752515	16.752515	17.248044	17.248044	20.855597	20.855597	22.835901
22.835901							
##	89	90	91	92	93	94	95
96							
##	23.124526	23.124526	23.087764	23.087764	23.148372	23.148372	22.989073
22.989073							
##	97	98	99	100	101	102	103
104							
##	22.982946	22.982946	23.012919	23.012919	23.225288	23.225288	23.148372
23.148372							
##	105	106	107	108	109	110	111
112							
##	23.093891	23.093891	22.918283	22.918283	22.952312	22.952312	22.989073
22.989073							
##	113	114	115	116	117	118	119
120							
##	23.195316	23.195316	23.059863	23.059863	23.124526	23.124526	22.989073
22.989073							
##	121	122	123	124	125	126	127
128							
##	23.266106	23.266106	25.359168	25.359168	35.510370	35.510370	38.792966
38.792966							
##	129	130	131	132	133	134	135
136							
##	38.515271	38.515271	38.657513	38.657513	38.509806	38.509806	38.509806
38.509806							
##	137	138	139	140	141	142	143
144							
##	38.580596	38.580596	38.620090	38.620090	38.586723	38.586723	38.651386
38.651386							
##	145	146	147	148	149	150	151
152							
##	38.651386	38.651386	38.368226	38.368226	38.580596	38.580596	38.792966
38.792966							
##	153	154	155	156	157	158	159

160
38.232773 38.232773 38.722176 38.722176 38.368226 38.368226 38.432889
38.432889
161 162 163 164 165 166 167
168
38.509806 38.509806 38.543835 38.543835 38.580596 38.580596 38.473045
38.473045
169 170 171 172 173 174 175
176
39.577120 39.577120 43.749754 43.749754 46.034331 46.034331 46.534002
46.534002
177 178 179 180 181 182 183
184
46.470001 46.470001 46.362450 46.362450 46.291660 46.291660 46.504029
46.504029
185 186 187 188 189 190 191
192
46.574819 46.574819 46.079290 46.079290 46.150080 46.150080 46.014627
46.014627
193 194 195 196 197 198 199
200
46.186841 46.186841 46.540791 46.540791 46.470001 46.470001 46.328421
46.328421
201 202 203 204 205 206 207
208
46.433239 46.433239 45.725340 45.725340 46.362450 46.362450 46.798781
46.798781
209 210 211 212 213 214 215
216
50.558182 50.558182 54.100178 54.100178 53.828610 53.828610 54.170968
54.170968
217 218 219 220 221 222 223
224
53.964725 53.964725 54.094051 54.094051 53.533858 53.533858 53.715594
53.715594
225 226 227 228 229 230 231
232
53.958598 53.958598 54.204996 54.204996 53.893935 53.893935 53.681565
53.681565
233 234 235 236 237 238 239
240
54.177094 54.177094 54.029388 54.029388 54.170968 54.170968 53.899400
53.899400
241 242 243 244 245 246 247
248
54.170968 54.170968 54.111770 54.111770 54.075670 54.075670 53.893935
53.893935
249 250 251 252 253 254 255
256
53.786384 53.786384 54.106305 54.106305 53.361644 53.361644 55.682149

```

55.682149
##      257      258      259      260      261      262      263
264
## 58.765205 58.765205 56.919202 56.919202 56.913737 56.913737 56.919864
56.919864
##      265      266      267      268      269      270      271
272
## 56.533957 56.533957 56.386912 56.386912 56.670071 56.670071 56.457702
56.457702
##      273      274      275      276      277      278      279
280
## 56.452236 56.452236 56.546872 56.546872 56.181330 56.181330 56.824566
56.824566
##      281      282      283      284      285      286      287
288
## 57.401816 57.401816 56.457702 56.457702 57.094811 57.094811 57.113191
57.113191
##      289      290      291      292      293      294      295
296
## 57.802710 57.802710 56.670071 56.670071 52.918206 52.918206 53.802805
53.802805
##      297      298      299      300      301      302      303
304
## 54.158912 54.158912 54.190956 54.190956 56.563036 56.563036 60.200561
60.200561
##      305      306      307      308      309      310      311
312
## 57.720586 57.720586 59.346021 59.346021 60.583478 60.583478 57.945871
57.945871
##      313      314
## 57.945871 57.945871

predict(model.distance.ultrasonic, df_test_ultrasonic)

##      1      2      3      4      5      6      7
8
## 8.641835 8.641835 8.537758 8.537758 8.641835 8.641835 8.641835
8.641835
##      9     10     11     12     13     14     15
16
## 8.537758 8.537758 8.641835 8.641835 8.641835 8.641835 8.537758
8.537758
##     17     18     19     20     21     22     23
24
## 8.641835 8.641835 8.641835 8.641835 8.537758 8.537758 8.641835
8.641835
##     25     26     27     28     29     30     31
32
## 8.624489 8.624489 8.520411 8.520411 8.641835 8.641835 8.641835
8.641835

```

##	33	34	35	36	37	38	39
40							
##	15.059964	15.059964	17.557830	17.557830	17.557830	17.557830	18.008833
18.008833							
##	41	42	43	44	45	46	47
48							
##	17.609869	17.609869	18.026180	18.026180	17.713946	17.713946	17.609869
17.609869							
##	49	50	51	52	53	54	55
56							
##	17.592522	17.592522	17.609869	17.609869	17.609869	17.609869	17.592522
17.592522							
##	57	58	59	60	61	62	63
64							
##	17.557830	17.557830	17.609869	17.609869	17.592522	17.592522	17.609869
17.609869							
##	65	66	67	68	69	70	71
72							
##	17.609869	17.609869	17.609869	17.609869	17.609869	17.609869	17.713946
17.713946							
##	73	74	75	76	77	78	79
80							
##	17.609869	17.609869	17.609869	17.609869	17.609869	17.609869	18.026180
18.026180							
##	81	82	83	84	85	86	87
88							
##	17.609869	17.609869	17.609869	17.609869	17.401713	17.401713	22.206636
22.206636							
##	89	90	91	92	93	94	95
96							
##	22.622947	22.622947	22.518869	22.518869	23.091297	23.091297	22.640293
22.640293							
##	97	98	99	100	101	102	103
104							
##	22.622947	22.622947	23.108643	23.108643	23.108643	23.108643	23.091297
23.091297							
##	105	106	107	108	109	110	111
112							
##	22.536216	22.536216	22.640293	22.640293	22.536216	22.536216	22.640293
22.640293							
##	113	114	115	116	117	118	119
120							
##	22.622947	22.622947	22.640293	22.640293	22.622947	22.622947	22.640293
22.640293							
##	121	122	123	124	125	126	127
128							
##	22.622947	22.622947	22.536216	22.536216	29.630849	29.630849	37.922377
37.922377							
##	129	130	131	132	133	134	135
136							

38.338688 38.338688 37.939723 37.939723 37.922377 37.922377 37.922377
37.922377
137 138 139 140 141 142 143
144
37.922377 37.922377 38.234610 38.234610 37.939723 37.939723 37.922377
37.922377
145 146 147 148 149 150 151
152
37.922377 37.922377 37.922377 37.922377 37.922377 37.922377 37.922377
37.922377
153 154 155 156 157 158 159
160
37.939723 37.939723 37.922377 37.922377 37.922377 37.922377 37.905031
37.905031
161 162 163 164 165 166 167
168
37.922377 37.922377 37.818299 37.818299 37.922377 37.922377 37.818299
37.818299
169 170 171 172 173 174 175
176
38.338688 38.338688 40.732476 40.732476 45.797594 45.797594 47.011834
47.011834
177 178 179 180 181 182 183
184
46.630216 46.630216 46.526138 46.526138 46.526138 46.526138 46.526138
46.526138
185 186 187 188 189 190 191
192
46.526138 46.526138 46.526138 46.526138 46.526138 46.526138 46.543484
46.543484
193 194 195 196 197 198 199
200
46.630216 46.630216 46.630216 46.630216 46.630216 46.630216 46.630216
46.630216
201 202 203 204 205 206 207
208
46.526138 46.526138 46.526138 46.526138 46.526138 46.526138 46.959795
46.959795
209 210 211 212 213 214 215
216
47.983227 47.983227 57.610419 57.610419 58.044076 58.044076 57.610419
57.610419
217 218 219 220 221 222 223
224
57.627765 57.627765 57.593073 57.593073 57.610419 57.610419 57.523687
57.523687
225 226 227 228 229 230 231
232
57.610419 57.610419 57.506341 57.506341 57.627765 57.627765 57.627765
57.627765

```

##      233      234      235      236      237      238      239
240
## 57.627765 57.627765 57.610419 57.610419 57.610419 57.610419 58.044076
58.044076
##      241      242      243      244      245      246      247
248
## 57.610419 57.610419 58.044076 58.044076 57.541034 57.541034 57.627765
57.627765
##      249      250      251      252      253      254      255
256
## 57.523687 57.523687 57.627765 57.627765 57.523687 57.523687 59.483818
59.483818
##      257      258      259      260      261      262      263
264
## 65.607060 65.607060 65.190749 65.190749 64.774438 64.774438 64.791784
64.791784
##      265      266      267      268      269      270      271
272
## 65.502982 65.502982 65.086671 65.086671 65.086671 65.086671 65.086671
65.086671
##      273      274      275      276      277      278      279
280
## 64.670360 64.670360 65.138710 65.138710 64.705052 64.705052 64.722399
64.722399
##      281      282      283      284      285      286      287
288
## 65.555021 65.555021 65.086671 65.086671 65.086671 65.086671 65.138710
65.138710
##      289      290      291      292      293      294      295
296
## 65.086671 65.086671 65.086671 65.086671 65.086671 65.086671 73.603700
73.603700
##      297      298      299      300      301      302      303
304
## 76.014835 76.014835 77.107651 77.107651 75.806680 75.806680 76.084220
76.084220
##      305      306      307      308      309      310      311
312
## 70.065057 70.065057 69.856901 69.856901 69.752823 69.752823 69.700785
69.700785
##      313      314
## 69.700785 69.700785

predict(model.distance.laser, df_test_laser)

##      1      2      3      4      5      6      7
8
## 6.765219 6.765219 6.439088 6.439088 6.656509 6.656509 6.982639
6.982639
##      9     10     11     12     13     14     15

```

16							
##	6.873929	6.873929	6.873929	6.873929	6.982639	6.982639	6.873929
6.873929							
##	17	18	19	20	21	22	23
24							
##	7.091350	7.091350	6.982639	6.982639	6.873929	6.873929	6.656509
6.656509							
##	25	26	27	28	29	30	31
32							
##	6.873929	6.873929	6.873929	6.873929	7.091350	7.091350	12.744283
12.744283							
##	33	34	35	36	37	38	39
40							
##	16.766563	16.766563	16.657853	16.657853	16.766563	16.766563	16.766563
16.766563							
##	41	42	43	44	45	46	47
48							
##	16.766563	16.766563	16.549143	16.549143	16.657853	16.657853	16.766563
16.766563							
##	49	50	51	52	53	54	55
56							
##	16.549143	16.549143	16.657853	16.657853	16.657853	16.657853	16.983984
16.983984							
##	57	58	59	60	61	62	63
64							
##	16.766563	16.766563	16.657853	16.657853	16.875274	16.875274	16.766563
16.766563							
##	65	66	67	68	69	70	71
72							
##	16.766563	16.766563	16.766563	16.766563	17.092694	17.092694	16.983984
16.983984							
##	73	74	75	76	77	78	79
80							
##	16.766563	16.766563	16.549143	16.549143	16.766563	16.766563	16.766563
16.766563							
##	81	82	83	84	85	86	87
88							
##	16.440433	16.440433	17.201404	17.201404	22.854338	22.854338	23.289179
23.289179							
##	89	90	91	92	93	94	95
96							
##	23.506600	23.506600	23.506600	23.506600	23.289179	23.289179	23.289179
23.289179							
##	97	98	99	100	101	102	103
104							
##	23.289179	23.289179	23.071759	23.071759	23.397890	23.397890	23.289179
23.289179							
##	105	106	107	108	109	110	111
112							
##	23.506600	23.506600	23.180469	23.180469	23.289179	23.289179	23.289179

23.289179							
##	113	114	115	116	117	118	119
120							
##	23.615310	23.615310	23.397890	23.397890	23.506600	23.506600	23.289179
23.289179							
##	121	122	123	124	125	126	127
128							
##	23.724020	23.724020	26.985328	26.985328	38.726037	38.726037	39.269589
39.269589							
##	129	130	131	132	133	134	135
136							
##	38.617327	38.617327	39.052168	39.052168	38.834747	38.834747	38.834747
38.834747							
##	137	138	139	140	141	142	143
144							
##	38.943458	38.943458	38.834747	38.834747	38.943458	38.943458	39.052168
39.052168							
##	145	146	147	148	149	150	151
152							
##	39.052168	39.052168	38.617327	38.617327	38.943458	38.943458	39.269589
39.269589							
##	153	154	155	156	157	158	159
160							
##	38.399906	38.399906	39.160878	39.160878	38.617327	38.617327	38.726037
38.726037							
##	161	162	163	164	165	166	167
168							
##	38.834747	38.834747	38.943458	38.943458	38.943458	38.943458	38.834747
38.834747							
##	169	170	171	172	173	174	175
176							
##	40.247981	40.247981	45.357364	45.357364	46.118335	46.118335	46.227046
46.227046							
##	177	178	179	180	181	182	183
184							
##	46.335756	46.335756	46.227046	46.227046	46.118335	46.118335	46.444466
46.444466							
##	185	186	187	188	189	190	191
192							
##	46.553176	46.553176	45.792205	45.792205	45.900915	45.900915	45.683494
45.683494							
##	193	194	195	196	197	198	199
200							
##	45.900915	45.900915	46.444466	46.444466	46.335756	46.335756	46.118335
46.118335							
##	201	202	203	204	205	206	207
208							
##	46.335756	46.335756	45.248653	45.248653	46.227046	46.227046	46.661887
46.661887							
##	209	210	211	212	213	214	215

216
 ## 51.879980 51.879980 52.097400 52.097400 51.445138 51.445138 52.206110
 52.206110
 ## 217 218 219 220 221 222 223
 224
 ## 51.879980 51.879980 52.097400 52.097400 51.227718 51.227718 51.553849
 51.553849
 ## 225 226 227 228 229 230 231
 232
 ## 51.879980 51.879980 52.314821 52.314821 51.771269 51.771269 51.445138
 51.445138
 ## 233 234 235 236 237 238 239
 240
 ## 52.206110 52.206110 51.988690 51.988690 52.206110 52.206110 51.553849
 51.553849
 ## 241 242 243 244 245 246 247
 248
 ## 52.206110 52.206110 51.879980 51.879980 52.097400 52.097400 51.771269
 51.771269
 ## 249 250 251 252 253 254 255
 256
 ## 51.662559 51.662559 52.097400 52.097400 51.010297 51.010297 53.510634
 53.510634
 ## 257 258 259 260 261 262 263
 264
 ## 54.923867 54.923867 52.314821 52.314821 52.532241 52.532241 52.532241
 52.532241
 ## 265 266 267 268 269 270 271
 272
 ## 51.553849 51.553849 51.553849 51.553849 51.988690 51.988690 51.662559
 51.662559
 ## 273 274 275 276 277 278 279
 280
 ## 51.879980 51.879980 51.771269 51.771269 51.445138 51.445138 52.423531
 52.423531
 ## 281 282 283 284 285 286 287
 288
 ## 52.858372 52.858372 51.662559 51.662559 52.640951 52.640951 52.640951
 52.640951
 ## 289 290 291 292 293 294 295
 296
 ## 53.728054 53.728054 51.988690 51.988690 46.227046 46.227046 42.965738
 42.965738
 ## 297 298 299 300 301 302 303
 304
 ## 42.204766 42.204766 41.661214 41.661214 46.009625 46.009625 51.445138
 51.445138
 ## 305 306 307 308 309 310 311
 312
 ## 50.901587 50.901587 53.510634 53.510634 55.467418 55.467418 51.445138

```
51.445138
##      313      314
## 51.445138 51.445138
```

-Estas líneas de código lo que realizan es que guardan los modelos lineales entrenados en formato RDS, en la carpeta “models” del paquete.

```
folder <- dirname(rstudioapi::getSourceEditorContext())$path
parentFolder <- dirname(folder)
saveRDS(model.distance.laser,
paste0(parentFolder, "/models/model_laser_distance.rds"))
saveRDS(model.distance.ultrasonic,
paste0(parentFolder, "/models/model_ultrasonic.rds"))
saveRDS(model.multi.distance,
paste0(parentFolder, "/models/model_laser_ultrasonic_distance.rds"))
```

2. Predicción de una variable categorica

En esta sección vamos a realizar la predicción de los datos obtenidos por cada sensor para categorizar las diferentes superficies, plana, concava o convexa.

```
if(!require(tidyverse))
  install.packages("tidyverse")
library(tidyverse)
if(!require(caret))
  install.packages("caret")
library(caret)

shape_df <- load_datasets("sensors_shapes_dataset.csv")
shape_df$Shape <- as.factor(shape_df$Shape)
head(shape_df)

##   count ultrasonic laser distance  Shape
## 1     1         804   142        10 convex
## 2     2         804   145        10 convex
## 3     3         804   145        10 convex
## 4     4         804   146        10 convex
## 5     5         804   146        10 convex
## 6     6         780   142        10 convex

set.seed(1)
data.train.idx <- createDataPartition(shape_df$Shape, p = 0.7, list =
FALSE)
train.data = shape_df[data.train.idx,]
test.data = shape_df[-data.train.idx,]
```

-Entrenamiento de los datos con hold out cross-validation (70-30).

```
ctrl <- trainControl(method="LGOVCV", p = 0.3)
shape.model.classificator <- train(
  Shape ~ ultrasonic + laser,
```

```

    data = train.data,
    method = "knn",
    tuneGrid = data.frame(k = 3),
    trControl = ctrl,
  )

```

-predicción de los datos

```

predictions <- predict(shape.model.classifier, test.data)
confusionMatrix(predictions, test.data$Shape)

## Confusion Matrix and Statistics
##
##              Reference
## Prediction concave convex plane
##   concave      58      0      0
##   convex       0     58      0
##   plane        2      2     60
##
## Overall Statistics
##
##              Accuracy : 0.9778
##              95% CI : (0.9441, 0.9939)
##   No Information Rate : 0.3333
##   P-Value [Acc > NIR] : < 2.2e-16
##
##              Kappa : 0.9667
##
##  McNemar's Test P-Value : NA
##
## Statistics by Class:
##
##              Class: concave Class: convex Class: plane
## Sensitivity              0.9667              0.9667              1.0000
## Specificity              1.0000              1.0000              0.9667
## Pos Pred Value           1.0000              1.0000              0.9375
## Neg Pred Value           0.9836              0.9836              1.0000
## Prevalence               0.3333              0.3333              0.3333
## Detection Rate           0.3222              0.3222              0.3333
## Detection Prevalence     0.3222              0.3222              0.3556
## Balanced Accuracy         0.9833              0.9833              0.9833

confusionMatrix(predictions, test.data$Shape)$overall["Accuracy"]

## Accuracy
## 0.9777778

```

-Prueba con los datos aleatorios

```

random_df <- load_datasets("random_shape_dataset.csv")
random_df <- random_df %>% select("ultrasonic", "laser")
predict(shape.model.classifier, random_df)

```

## [1]	plane	plane	plane	plane	plane	plane	plane	plane
plane								
## [10]	plane	plane	plane	plane	plane	plane	plane	plane
plane								
## [19]	plane	plane	plane	plane	plane	plane	plane	plane
plane								
## [28]	plane	plane	plane	plane	plane	plane	plane	plane
plane								
## [37]	plane	plane	plane	plane	plane	plane	concave	concave
concave								
## [46]	concave	concave	concave	concave	concave	concave	concave	concave
concave								
## [55]	concave	concave	concave	concave	concave	concave	concave	concave
concave								
## [64]	concave	concave	concave	concave	concave	concave	concave	concave
concave								
## [73]	concave	concave	concave	concave	concave	concave	concave	concave
plane								
## [82]	plane	convex	convex	convex	convex	convex	convex	convex
convex								
## [91]	convex	convex	convex	convex	convex	convex	convex	convex
convex								
## [100]	convex	convex	convex	convex	convex	convex	convex	convex
convex								
## [109]	convex	convex	plane	plane	convex	convex	convex	convex
convex								
## [118]	convex	convex	convex	concave	concave	concave	concave	concave
concave								
## [127]	concave	concave	concave	concave	concave	concave	concave	concave
concave								
## [136]	concave	concave	concave	concave	concave	concave	concave	concave
concave								
## [145]	concave	concave	concave	concave	concave	concave	concave	concave
concave								
## [154]	concave	concave	concave	concave	concave	concave	concave	convex
convex								
## [163]	convex	convex	convex	convex	convex	convex	convex	convex
convex								
## [172]	convex	convex	convex	convex	convex	convex	convex	convex
convex								
## [181]	convex	convex	convex	convex	convex	convex	convex	convex
convex								
## [190]	convex	convex	convex	convex	convex	convex	convex	convex
convex								
## [199]	convex	convex	convex	plane	plane	convex	convex	plane
plane								
## [208]	convex	convex	plane	plane	convex	convex	plane	plane
convex								
## [217]	convex	plane	plane	convex	convex	plane	plane	convex
convex								


```
## [451] concave concave concave concave concave concave concave concave
concave
## [460] concave concave concave concave concave concave concave concave
concave
## [469] concave concave concave concave concave concave concave concave
concave
## [478] concave concave concave concave concave concave concave concave
concave
## [487] plane plane concave concave concave concave concave concave
concave
## [496] concave concave concave concave concave concave concave concave
concave
## [505] concave concave concave concave concave concave concave concave
concave
## [514] concave concave concave concave concave concave concave concave
concave
## [523] concave concave plane plane concave concave concave concave
concave
## [532] concave concave concave concave concave concave concave concave
concave
## [541] concave concave concave concave concave concave concave concave
concave
## [550] concave concave concave concave concave concave concave concave
concave
## [559] concave concave concave concave concave concave concave concave
concave
## [568] concave concave concave plane plane convex convex convex
convex
## [577] convex convex convex convex convex convex convex convex
convex
## [586] convex convex convex convex convex convex convex convex
convex
## [595] convex convex convex convex convex convex
## Levels: concave convex plane
```

-Almacenar el modelo

```
folder <- dirname(rstudioapi::getSourceEditorContext())$path)
parentFolder <- dirname(folder)
saveRDS(shape.model.classificator,
paste0(parentFolder, "/models/shape_model_classificator.rds"))
```

##Conclusiones de los modelos -Con la libreria Caret se pudo realizar el entrenamiento de los datos de una forma mas eficiente y con una interfaz fácil si se comprenden las bases de su funcionamiento. Esto también nos ahorra tiempo ya que se automatiza el proceso de construcción de modelos de regresión lineal y modelos de predicción de Knn.

-Se garantiza que los datos tengan una mejor limpieza, lo que minimiza el ruido al momento de la captura de los datos.

-Ayuda al preprocesamiento de datos de clasificación categorica, si estos datos seran empleados al momento de clasificar la forma de las superficies.

-Cuando se realizaron la toma de datos y se procesaron, y por ultimo se realiza el modelo de predicción la distancia no es un dato predictor para poder clasificar la forma de la superficie.

-El modelo Knn es un modelo que se utiliza para calificar objetos de diferentes categorías, por lo que se basa en la similitud entre los datos y los objetos del entrenamiento..